

Домашнее задание 4 Вариант 4

Выполнил: Мосолков Евгений Николаевич БПИ196

Примечание:

Вычисления были сделаны при помощи Python и Jupiter notebook. Среди использованных библиотек – pandas, scipy, matplotlib

Задание:

1. Для признаков framerate, frames, bitrate, duration и size рассчитайте две корреляционные матрицы — на основании коэффициентов Пирсона и Спирмена. Оцените значимость каждого коэффициента (проверьте гипотезу об отсутствии корреляции) и представьте полученные результаты в виде таблицы
2. Сравните коэффициенты Пирсона и Спирмена, обратите внимание на случаи, когда два этих коэффициента существенно расходятся, если такие есть. Что такое «существенно», решайте сами. В случае существенного расхождения постройте диаграммы разброса для тех пар признаков, тесноту связи между которыми коэффициенты измеряют по-разному, и попытайтесь объяснить причину расхождения. Если вы не видите никаких существенных расхождений между двумя матрицами, просто постройте диаграмму рассеяния для случая, где разность коэффициентов Пирсона и Спирмена наибольшая

Решение:

1. Найдем матрицу корреляции Пирсона

Считаем сумму средних значений столбцов, затем среднее арифметическое столбцов. Теперь считаем отклонения от среднего арифметического для каждого значения из каждого столбца. Возводим отклонения в квадрат и считаем сумму отклонений.

Далее считаем коэффициенты корреляции по формуле:

$$r_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 * \sum (y_i - \bar{y})^2}}$$

Определяем значимость коэффициента корреляции по формуле:

$$t = r_{xy} \frac{\sqrt{n-2}}{\sqrt{1-r_{xy}^2}}$$

Расставляем метки, сравнивая значения со значениями из таблицы Стьюдента и получаем таблицу:

	framerate	frames	bitrate	duration	size
framerate	1	0.300**	0.343***	0.090	0.290**
frames	0.300**	1	0.009	0.902***	0.549***
bitrate	0.343***	0.009	1	-0.041	0.586***
duration	0.090	0.902***	-0.041	1	0.443***
size	0.290**	0.549***	0.586***	0.443***	1

2. Найдем матрицу корреляции Спирмена

Для этого необходимо про ранжировать данные по столбцам, затем вычислить разность рангов по каждому случаю. Полученную разность нужно возвести в квадрат. Далее находим сумму квадратов разностей.

Теперь вычислим значения, которые попадут в матрицу по формуле:

$$p = 1 - 6 \frac{\sum d^2}{n^3 - n}$$

Определяем значимость коэффициента корреляции по формуле:

$$t = p \frac{\sqrt{n-2}}{\sqrt{1-p^2}}$$

Расставляем метки, сравнивая значения со значениями из таблицы Стьюдента и получаем таблицу:

	framerate	frames	bitrate	duration	size
framerate	1	0.510***	0.648***	0.225*	0.605***
frames	0.510***	1	0.373***	0.937***	0.799***
bitrate	0.648***	0.373***	1	0.152	0.807***
duration	0.225*	0.937***	0.152	1	0.653***
size	0.605***	0.799***	0.807***	0.653***	1

	framerate	frames	bitrate	duration	size
framerate	1	0.300**	0.343***	0.090	0.290**
frames	0.300**	1	0.009	0.902***	0.549***
bitrate	0.343***	0.009	1	-0.041	0.586***
duration	0.090	0.902***	-0.041	1	0.443***
size	0.290**	0.549***	0.586***	0.443***	1

Наибольший разброс наблюдается у следующих пар параметров:

1. framerate и bitrate
2. frames и bitrate
3. framerate и size

Построим диаграммы для каждой из пар параметров:

